

1 MOT 问题定义

多目标跟踪 (MOT) 任务旨在通过对一系列连续时刻的观测数据进行分析, 估计和跟踪多个目标的运动轨迹。

具体的, 我们定义如下量:

- 时刻 t 的真实目标状态集合:

$$S = \{s_1, s_2, \dots, s_m\}.$$

- 时刻 $t - 1$ 的最优状态估计集合:

$$T = \{t_1, t_2, \dots, t_n\}.$$

- 时刻 t 的目标检测 (状态观测) 集合:

$$D = \{d_1, d_2, \dots, d_h\}.$$

- 时刻 t 要求得到的最优状态估计集合:

$$\hat{T} = \{\hat{t}_1, \hat{t}_2, \dots, \hat{t}_p\}.$$

我们的目标是求解 $\hat{T}$, 使得下式达到最小:

$$\sum_{i=1}^k \|\hat{t}_i - s_i\|_2^2,$$

其中

$$k = \max(m, p).$$

1.1 单目标最优估计问题

对于这个函数可以进一步拆分为多个单项最小化问题。对于每个目标的估计, 我们可以将其单独处理, 使得每个目标的状态估计问题简化为单目标状态估计问题。具体来说, 对于每个目标 i , 我们要求最小化以下目标函数:

$$\|\hat{t}_i - s_i\|_2^2,$$

其中 $\hat{t}_i$ 是目标 i 在时刻 t 的最优状态估计, s_i 是目标 i 在时刻 t 的真实状态。

在这种简化的情况下，单目标状态估计问题的数学模型通常可以通过卡尔曼滤波、粒子滤波等方法来求解，其中卡尔曼滤波特别适用于线性动态系统。

1.2 目标对齐与检测匹配问题

在多目标跟踪问题中，除了最小化每个目标的状态估计误差外，另一个关键问题是目标的对齐，即如何确保每个估计目标与真实目标之间建立正确的一一对应关系。这个对齐问题涉及两个方面：数量上的一致性和真实性上的一致性。

我们要求在时刻 t 的状态估计 $\hat{T}$ 和真实目标状态 S 之间建立准确的对应关系。具体而言，目标对齐的要求包括：

1. 数量一致性：估计目标的数量应与实际目标的数量相等，即：

$$p = m = k.$$

2. 物理世界一致性：每个估计目标 $\hat{t}_i$ 与真实目标 s_i 必须表示同一物理世界中的目标，即，它们需要具有一一对应关系。在这种情况下，误差最小化是通过以下目标函数实现的：

$$\sum_{i=1}^k \|\hat{t}_i - s_i\|_2^2,$$

其中， $k = \max(m, p)$ ， m 是真实目标数量， p 是估计目标数量。

2 问题的进一步研究-单目标状态估计

2.1 单目标状态估计

在本节中，我们探讨单目标状态估计问题。假设在时刻 t 和时刻 $t-1$ ，我们有一对目标检测 D_t 和先前的状态估计 T_{t-1} ，我们希望通过结合这两者来估计当前时刻的目标状态 $\hat{T}_t$ 。

为了描述目标的运动过程，我们假设目标在连续时间内服从某种时变非线性状态空间模型。假设目标的状态演化可以由以下的状态转移方程和观测方程来描述：

已知:

- t 时刻的目标观测值 D_t 。
- $t - 1$ 时刻的目标状态估计 T_{t-1} 。

寻找一个最优估计函数 $f(\cdot)$ ，使得估计 $\hat{T}_t = f(D_t, T_{t-1})$ 最优:

$$\hat{T}_t^* = \arg \min_{f(\cdot)} \left\| \hat{T}_t - S_t \right\|_2^2$$

为了方便描述，我们用 x_t 来表示目标状态 T_t ，用 z_t 来表示观测值 D_t 。目标的状态演化可以由以下的时变非线性状态空间模型描述:

$$x_t = f_t(x_{t-1}) + w_t$$

$$z_t = h_t(x_t) + v_t$$

其中:

- x_t 为目标的状态向量，即 T_t
- $f_t(\cdot)$ 非线性函数，描述从时刻 $t - 1$ 到时刻 t 的状态演化
- $w_t \sim \mathcal{N}(0, Q_t)$ 为过程噪声
- z_t 为时刻 t 的观测值，也就是 D_t
- $h_t(\cdot)$ 是观测函数，将状态空间映射到观测空间，即 I
- $v_t \sim \mathcal{N}(0, R_t)$ 为观测噪声

2.1.1 卡尔曼滤波方法

经典的卡尔曼滤波 (Kalman Filter) 是一种用于线性系统状态估计的递归算法。卡尔曼滤波的基本思想是在状态空间模型的基础上进行递归估计，通过假设系统模型为线性，并且噪声为高斯分布，从而可以通过最小均方误差 (MMSE) 准则对目标状态进行估计。

卡尔曼滤波器的状态估计和协方差矩阵更新步骤如下:

预测阶段:

$$\hat{x}_{t|t-1} = A\hat{x}_{t-1|t-1}$$

$$P_{t|t-1} = AP_{t-1|t-1}A^T + Q$$

更新阶段：

$$K_t = P_{t|t-1} H^T (H P_{t|t-1} H^T + R)^{-1}$$

$$\hat{x}_{t|t} = \hat{x}_{t|t-1} + K_t (z_t - H \hat{x}_{t|t-1})$$

$$P_{t|t} = (I - K_t H) P_{t|t-1}$$

其中：

- K_t 是卡尔曼增益，决定了预测值与观测值的权重。
- $\hat{x}_{t|t-1}$ 是预测的状态估计。
- $P_{t|t-1}$ 是预测的协方差矩阵，表示估计的可靠性。
- H_t 是观测矩阵，定义了状态到观测的映射。
- $\hat{x}_{t|t}$ 是当前时刻的最优状态估计。
- $P_{t|t}$ 是更新后的协方差矩阵。

2.1.2 卡尔曼滤波的假设及其局限性

卡尔曼滤波的效果和假设紧密相关，这些假设在某些情况下可能会导致效果不佳：

- 运动模型假设：卡尔曼滤波假设系统模型是线性且时不变的。然而，现实中的运动模型往往是非线性的，且不同类型的目标（如跑车、轿车等）可能有不同的运动模型，导致卡尔曼滤波的估计不准确。
- 噪声假设：卡尔曼滤波假设过程噪声和观测噪声是高斯分布且时不变的。但在实际应用中，噪声可能是时变的，且并不总是遵循高斯分布，特别是在复杂环境下，非高斯噪声的存在可能影响估计精度。
- 初值问题：卡尔曼滤波对初始状态估计非常敏感。如果初值选择不准确，可能会导致滤波过程中的累积误差，影响最终的状态估计。

这些假设在某些复杂场景中可能会引入误差，尤其是当目标系统的行为与卡尔曼滤波的假设不符时。为了克服这些局限性，研究人员提出了扩展卡尔曼滤波（EKF）和无迹卡尔曼滤波（UKF）等方法，它们能够处理一定程度的非线性问题，并且更能适应复杂的噪声环境，但这些方法仍然面临着处理高维度和非高斯噪声的挑战。

2.2 前沿论文调研

为了提升每个目标的状态估计效果，学界提出了多种改进方法，主要包括基于检测质量自适应调整噪声的 NSA Kalman Filter，以及利用检测器统计噪声建模的 RobMOT。

GIAOTRACK: NSA Kalman Filter

GIAOTRACK 虽然是一种 offline 的方法，但其提出的 NSA Kalman Filter (NSA KF) 在之后的系列工作中受到了广泛采用。NSA KF 的核心思想是：基于检测置信度自适应调整测量噪声协方差，从而补偿传统 KF 对噪声固定假设的不足。该方法通过检测置信度来动态调节测量噪声，使得在低置信度检测下，滤波器能够更谨慎地更新状态。

1. 固定测量噪声协方差预设

$$R_k \in \mathbb{R}^{d \times d}, \quad d = \text{测量维度}$$

2. 检测置信度

$$c_k \in [0, 1], \quad \text{表示第 } k \text{ 帧检测置信度}$$

3. 自适应测量噪声 (NSA 核心公式)

$$\tilde{R}_k = (1 - c_k) R_k \quad (1)$$

4. NSA Kalman Filter 更新步骤

- $\tilde{y}_k = z_k - H_k \hat{x}_{k|k-1}$
- $\tilde{R}_k = (1 - c_k) R_k$
- $S_k = H_k P_{k|k-1} H_k^T + \tilde{R}_k$
- $K_k = P_{k|k-1} H_k^T S_k^{-1}$
- $\hat{x}_{k|k} = \hat{x}_{k|k-1} + K_k \tilde{y}_k$
- $P_{k|k} = (I - K_k H_k) P_{k|k-1}$

潜在问题：不同检测器的置信度分布不同，可能导致噪声调整效果不一致。

RobMOT: 基于检测器噪声建模的稳健 KF

RobMOT 在 GIAOTRACK 的基础上进一步改进, 显式建模检测器在 x,y 方向上的统计误差, 并将其融入 KF 的创新协方差中。相比 NSA-KF 仅根据置信度调整噪声, RobMOT 通过数据驱动地估计检测器噪声统计, 使 KF 更新更加稳健。

1. 检测器噪声统计建模 通过对齐检测结果与 Ground Truth, 统计各维度误差的均值与方差:

$$\begin{aligned}\mu_x &= \frac{1}{\sum_{i=1}^N k_i} \sum_{i=1}^N \sum_{j=1}^{k_i} \left(z_{ij}^{gt}(x) - z_{ij}^{det}(x) \right) \\ \sigma_x^2 &= \frac{1}{\sum_{i=1}^N k_i} \sum_{i=1}^N \sum_{j=1}^{k_i} \left(\left(z_{ij}^{gt}(x) - z_{ij}^{det}(x) \right) - \mu_x \right)^2\end{aligned}\tag{2}$$

z_{ij}^{gt} 和 z_{ij}^{det} 分别表示 GT 与检测位置。对 y 方向重复同样的计算, 最终得到检测器噪声协方差矩阵:

$$D_t = \begin{bmatrix} \sigma_x^2 & 0 \\ 0 & \sigma_y^2 \end{bmatrix}\tag{3}$$

该矩阵量化了检测器在当前位置引入的不确定性。

2. 改进的 Kalman Filter 更新 RobMOT 将 D_t 显式加入创新协方差 S_t :

- $\tilde{y}_t = z_t - H_t \hat{x}_{t|t-1}$
- $S_t = H_t P_{t|t-1} H_t^T + R_t + D_t$
- $K_t = P_{t|t-1} H_t^T S_t^{-1}$
- $\hat{x}_{t|t} = \hat{x}_{t|t-1} + K_t \tilde{y}_t$
- $P_{t|t} = (I - K_t H_t) P_{t|t-1}$

通过显式考虑检测器的统计误差, RobMOT 在遮挡、远距离检测等低质量检测场景下, 显著降低了轨迹漂移, 提高了跟踪的稳定性与准确性。

KALMANNET: 通过神经网络隐式建模噪声

在系统动力学部分已知但噪声统计未知、甚至存在模型不匹配的情况下，利用深度学习提升 Kalman 滤波的实时状态估计能力。其实现框架可以概括为：在保持 Kalman Filter 结构（预测—更新）的前提下，用一个 RNN（GRU）学习“卡尔曼增益 K ”的计算方式。

KalmanNet 的核心思想是在保持卡尔曼滤波（Kalman Filter, KF）预测—更新结构的前提下，使用一个递归神经网络（RNN）来学习每个时刻的卡尔曼增益 K_t 。其整体架构可以被分为三个主要模块：预测（Prediction）、增益学习模块（Kalman Gain Learning Module）、以及更新（Update）。

1. Prediction Module

在预测阶段，KalmanNet 完全保留了模型驱动（Model-Based）KF 的结构，使用（可能并不精确的）系统动力学 $f(\cdot)$ 及观测模型 $h(\cdot)$ 来给出先验的状态与观测预测：

$$\hat{x}_{t|t-1} = f(\hat{x}_{t-1}), \quad (4)$$

$$\hat{y}_{t|t-1} = h(\hat{x}_{t|t-1}). \quad (5)$$

与经典 KF 不同的是：KalmanNet 不再显式维护或传播二阶统计量（如协方差矩阵 $\Sigma_{t|t-1}$ ），而是仅保留一阶矩，以便在更新时由 RNN 隐式学习这些统计量中的关键信息。

2. Kalman Gain Learning Module

为了让 RNN 能够隐式学习噪声统计与协方差传播，KalmanNet 对输入的观测和状态历史构造四类差分特征：

- **F1**: 连续观测差分 $\Delta \tilde{y}_t = y_t - y_{t-1}$;
- **F2**: 创新项差分 $\Delta y_t = y_t - \hat{y}_{t|t-1}$;
- **F3**: 相邻后验状态差分 $\Delta \tilde{x}_t = \hat{x}_{t|t} - \hat{x}_{t-1|t-1}$;
- **F4**: 后验与先验差分 $\Delta \hat{x}_t = \hat{x}_{t|t} - \hat{x}_{t|t-1}$ 。

上述特征能够有效携带系统动力学的变化信息与噪声统计信息，使得 RNN 可以通过这些时间序列学习卡尔曼增益的最优计算规律。

KalmanNet 采用一个结构紧凑的 RNN（通常为 GRU）来学习时变卡尔曼增益：

$$K_t = \text{RNN}(\text{features at time } t).$$

RNN 的设计有两种典型形式：

1. 单 GRU 大状态结构：一个较大维度的 GRU 隐状态同时隐式追踪过程噪声、观测噪声、预测协方差与创新协方差等二阶统计量；
2. 多 GRU 分模块结构：分别为过程噪声 Q 、预测协方差 $\Sigma_{t|t-1}$ 、创新协方差 S_t 建立三个 GRU，并按 KF 流程进行串联，使网络结构更具可解释性。

无论采用哪种结构，RNN 输出的 $K_t \in \mathbb{R}^{m \times n}$ 都直接用于更新步骤。

3. Update Module

更新步骤保持与 KF 完全相同的形式：

$$\hat{x}_t = \hat{x}_{t|t-1} + K_t(y_t - \hat{y}_{t|t-1}). \quad (6)$$

其中，创新项 $\Delta y_t = y_t - \hat{y}_{t|t-1}$ 依然是唯一依赖观测的量；区别仅在于增益 K_t 由 RNN 给出而非由 KF 的解析公式计算。

该架构既保留了 KF 的可解释性与结构优势，又通过数据驱动的增益学习克服模型不完备、噪声统计未知及强非线性带来的性能退化问题。